

Q-learning

Late rewards maken leren moeilijker

- Sommige problemen hebben pas een beloning helemaal op het einde
 - Mountain car krijgt enkel punten helemaal boven bij de vlag
 - Een taxichauffeur wordt pas betaald op de bestemming
 - Een diploma krijg je pas na 180 studenten en veel bloed, zweet en tranen
- Hoe kan een agent dan toch onderweg iets leren?

Late rewards maken leren moeilijker

- Sommige problemen hebben pas een beloning helemaal op het einde
 - Mountain car krijgt enkel punten helemaal boven bij de vlag
 - Een taxichauffeur wordt pas betaald op de bestemming
 - Een diploma krijg je pas na 180 studenten en veel bloed, zweet en tranen
- Hoe kan een agent dan toch onderweg iets leren?
 - We kunnen net zoals in explore vs exploit kijken naar **discounted rewards** in de toekomst

Een leeromgeving

- **Agents**
- **States**
- **Acties**, met bijbehorende...
- **Rewards**
- **Episodes**: een episode eindigt wanneer er een terminal state wordt bereikt

Strategie

Intuïtie

- Later een doel bereiken levert minder punten op (discounting)
- Per stap hebben we een idee van de 'verwachte rewards' voor elke actie
 - Dit gaan we bijhouden in een tabel, de **Q-tabel**
 - Deze tabel gaan we voortdurend updaten op basis van nieuwe informatie

Wiskunde

- Een q-tabel heeft voor elke combinatie (observatie, actie) een bepaalde waarde die de waarde van die actie voorstelt
- Op basis van een bepaalde observatie kan je dus inschatten wat, op basis van de op dat moment gekende informatie, de beste actie is
- Als je een actie doet, en je krijgt feedback (reward / penalty) dan kan je elke keer de tabel lichtjes bijstellen

Strategie

Startfase

- We starten met een q-tabel die voor elke observatie en elke actie een neutrale verwachting heeft

Q-tabel

Q-tabel	Actie 1	AC 2	Ac 3	Ac 4	Ac 5
Observatie 1	0	0	0	0	0
Ob 2	0	0	0	0	0
Ob 3	0	0	0	0	0
Ob 4	0	0	0	0	0
Ob 5	0	0	0	0	0

Strategie

Epsilon : explore vs exploit

- In elke fase gaan we met een vooraf bepaalde kanse epsilon kijken of we explore of exploit gaan doen
 - **Explore:** kies een random actie
 - **Exploit:** kies voor deze observatie de actie met de grootste verwachte Q-waarde
 - Bijvoorbeeld: bij een Q-tabel zoals hiernaast: voor obs 2 zou actie 4 worden gekozen, voor ob 3 zou actie 5 worden gekozen, voor al de rest geen voorkeur.

Q-tabel

Q-tabel	Actie 1	AC 2	Ac 3	Ac 4	Ac 5
Observatie 1	0	0	0	0	0
Ob 2	0	4	0	5	0
Ob 3	1	2	-2	-20	5
Ob 4	0	0	0	0	0
Ob 5	0	0	0	0	0

Strategie


Update fase

- Na de uitvoering van een keuze, krijg je van je omgeving een reward
- Deze reward gaan we terug in de tabel invoeren, via een updateformule. De exacte formule vindt je terug in de RL_voorbeelden.

Q-tabel

Q-tabel	Actie 1	AC 2	Ac 3	Ac 4	Ac 5
Observatie 1	0	0	0	0	0
Ob 2	0	4	0	5	0
Ob 3	1	2	-2	-20	5
Ob 4	0	0	0	0	0
Ob 5	0	0	0	0	0


Voorbeeld: een taxichauffeur



- **Penalties:**

- Elke move kost -1
- Het fout afzetten van een passagier kost zeer veel
- Dit gaan we bekijken in de notebook.

Reinforcement learning en zelfrijdende auto



Q-learning in de praktijk

- Zie notebook RL_voorbeelden en taxi_notebook.